Gestión, manipulación y visualización de series temporales | Summer School UPC 2021

Aurelio Tobías, Dominic Royé, Carmen Iñiguez

Contents

Tidyverse

El universo de los paquetes de `tidyverse`, una colección de paquetes de funciones para un uso especialmente enfocado en la ciencia de datos, abrió un antes y después en la programación de R. En este post voy a resumir muy brevemente lo más esencial para inicarse en este mundo. La gramática sigue en todas las funciones una estructura común. Lo más esencial es que el primer argumento es el objeto y a continuación viene el resto de argumentos. Además, se proporciona un conjunto de verbos que facilitan el uso de las funciones. En la actualidad, la filosofía de las funciones también se refleja en otros paquetes que hacen compatible su uso con la colección de `tidyverse`. Por ejemplo, el paquete `sf` (simple feature) para el tratamiento de datos vectoriales, permite el uso de múltiples funciones que encontramos en el paquete `dplyr`.

El núcleo de la colección lo constituyen los siguientes paquetes:

Paquete	Descripción
ggplot2	Gramática para la creación de gráficos
purrr	Programación funcional de R
tibble	Sistema moderno y efectivo de tablas
dplyr	Gramatica para la manipulación de datos
tidyr	Conjunto de funciones para ordenar datos
stringr	Conjunto de funciones para trabajar con caracteres
readr	Una forma fácil y rápida para importar datos
forcats	Herramientas y funciones para trabajar fácilmente con factores

Además de los paquetes menciondos, también se usa muy frecuentemente `lubridate` para trabajar con fechas

y horas, y también `readxl` que nos permite importar archivos en formato Excel. Para conocer todos los paquetes disponibles podemos emplear la función `tidyverse_packages()`.

```
##  [1] "broom"         "cli"           "crayon"        "dbplyr"
##  [5] "dplyr"         "dtplyr"        "forcats"       "googledrive"
##  [9] "googlesheets4" "ggplot2"       "haven"         "hms"
## [13] "httr"          "jsonlite"      "lubridate"     "magrittr"
## [17] "modelr"        "pillar"        "purrr"         "readr"
## [21] "readxl"        "reprex"        "rlang"         "rstudioapi"
## [25] "rvest"         "stringr"       "tibble"        "tidyr"
## [29] "xml2"          "tidyverse"
```

Es muy fácil encontrarnos con conflicos de funciones, o sea, que el mismo nombre de función exista en varios paquetes. Para evitarlo, podemos escribir el nombre del paquete delante de la función que queremos usar, separados por el símbolo de dos puntos escrito dos veces (`package_name::function_name`).

Antes de empezar con los paquetes, espero que sea verdaderamente una breve introducción, algunos comentarios sobre el estilo al programar en R.

Guía de estilo

En R no existe una guía de estilo universal, o sea, en la sintaxis de R no es necesario seguir normas concretas para nuestros scripts. Es recomendable trabajar de forma homogénea y clara a la hora de escribir con un estilo uniforme y legible. La colección de `tidyverse` tiene una guia propia (https://style.tidyverse.org/).

Las recomendaciones más importes son:

- Evitar usar más de 80 caracteres por línea para permitir leer el código completo.
- Usar siempre un espacio después de una coma, nunca antes.
- Los operadores (==, +, -, <-, %>%, etc.) deben tener un espacio antes y después.
- No hay espacio entre el nombre de una función y el primer paréntesis, ni entre el último arguemento y el paréntesis final de una función.
- Evitar reutilizar nombres de funciones y variables comunes (`c <- 5` vs. `c()`)
- Ordenar el script separando las partes con la forma de comentario `# Importar datos -----`
- Se deben evitar tildes o símbolos especiales en nombres, archivos, rutas, etc.
- Nombres de los objetos deben seguir una estructura constante: `day_one`, `day_1`.

Es aconsejable usar una correcta *indentación* para multiples argumentos de una función o funciones encadenadas por el operador `pipe` (`%>%`).

Pipe %>%

Para facilitar el trabajo en la gestión, manipulación y visualización de datos, el paquete `magrittr` introduce el operador llamado *pipe* en la forma `%>%` con el objetivo de combinar varias funciones sin la necesidad de asignar el resultado a un nuevo objeto. El operador *pipe* pasa a la salida de una función aplicada al primer argumento de la siguiente función. Esta forma de combinar funciones permite encadenar varios pasos de forma simultánea. En el siguiente ejemplo, muy sencillo, pasamos el vector `1:5` a la función `mean()` para calcular el promedio.

```
1:5 %>% mean()
```

```
## [1] 3
```

Paquetes de Tidyverse

Lectura y escritura

El paquete `readr` facilita la lectura o escritura de múltiples formatos de archivo usando funciones que comienzan por `read_*` o `write_*`. En comparación con *R Base* las funciones son más rápidas, ayudan a limpiar los nombres de las columnas y las fechas son convertidas automáticamente. Las tablas importadas son de clase `tibble` (**tbl_df**), una versión moderna de `data.frame` del paquete `tibble`. En el mismo sentido se puede usar la función `read_excel()` del paquete `readxl` para importar datos de hojas de Excel (más detalles también en esta entrada de mi blog). En el siguiente ejemplo importamos los datos de la movilidad registrada por Google (enlace) durante los últimos meses a causa de la pandemia COVID-19 (descarga).

Función lectura	Descripción
read_csv() o read_csv2()	coma o punto-coma (CSV)
read_delim()	separador general
read_table()	espacio blanco

```
# cargar el paquete
library(tidyverse)

google_mobility <- read_csv("./datos/Global_Mobility_Report.csv")
```

```
##
## -- Column specification --------------------------------------------------------
## cols(
##   country_region_code = col_character(),
##   country_region = col_character(),
##   sub_region_1 = col_character(),
##   sub_region_2 = col_logical(),
##   iso_3166_2_code = col_character(),
##   census_fips_code = col_logical(),
##   date = col_date(format = ""),
##   retail_and_recreation_percent_change_from_baseline = col_double(),
##   grocery_and_pharmacy_percent_change_from_baseline = col_double(),
##   parks_percent_change_from_baseline = col_double(),
##   transit_stations_percent_change_from_baseline = col_double(),
##   workplaces_percent_change_from_baseline = col_double(),
##   residential_percent_change_from_baseline = col_double()
## )
```

```
## Warning: 597554 parsing failures.
##    row              col           expected         actual                                file
## 200119 sub_region_2     1/0/T/F/TRUE/FALSE Autauga County './datos/Global_Mobility_Report.csv'
## 200119 census_fips_code 1/0/T/F/TRUE/FALSE 01001          './datos/Global_Mobility_Report.csv'
## 200120 sub_region_2     1/0/T/F/TRUE/FALSE Autauga County './datos/Global_Mobility_Report.csv'
## 200120 census_fips_code 1/0/T/F/TRUE/FALSE 01001          './datos/Global_Mobility_Report.csv'
## 200121 sub_region_2     1/0/T/F/TRUE/FALSE Autauga County './datos/Global_Mobility_Report.csv'
## ...... ................ ................... ............... ....................................
## See problems(...) for more details.
```

```
google_mobility
```

```
## # A tibble: 516,697 x 13
##    country_region_co~ country_region   sub_region_1 sub_region_2 iso_3166_2_code
##    <chr>              <chr>            <chr>        <lgl>        <chr>
```

```
##  1 AE                United Arab Emi~ <NA>         NA           <NA>
##  2 AE                United Arab Emi~ <NA>         NA           <NA>
##  3 AE                United Arab Emi~ <NA>         NA           <NA>
##  4 AE                United Arab Emi~ <NA>         NA           <NA>
##  5 AE                United Arab Emi~ <NA>         NA           <NA>
##  6 AE                United Arab Emi~ <NA>         NA           <NA>
##  7 AE                United Arab Emi~ <NA>         NA           <NA>
##  8 AE                United Arab Emi~ <NA>         NA           <NA>
##  9 AE                United Arab Emi~ <NA>         NA           <NA>
## 10 AE                United Arab Emi~ <NA>         NA           <NA>
## # ... with 516,687 more rows, and 8 more variables: census_fips_code <lgl>,
## #   date <date>, retail_and_recreation_percent_change_from_baseline <dbl>,
## #   grocery_and_pharmacy_percent_change_from_baseline <dbl>,
## #   parks_percent_change_from_baseline <dbl>,
## #   transit_stations_percent_change_from_baseline <dbl>,
## #   workplaces_percent_change_from_baseline <dbl>,
## #   residential_percent_change_from_baseline <dbl>
```

Debemos prestar atención a los nombres de los argumentos, ya que cambian en las funciones de `readr`. Por ejemplo, el argumento conocido `header = TRUE` de `read.csv()` es en este caso `col_names = TRUE`. Podemos encontrar más detalles en el Cheat-Sheet de `readr` .

Manipulación de caracteres

Cuando se requiere manipular cadenas de texto usamos el paquete `stringr`, cuyas funciones siempre empiezan por `str_*` seguidas por un verbo y el primer argumento.

Algunas de estas funciones son las siguientes:

Función	Descripción
str_replace()	reemplazar patrones
str_c()	combinar characteres
str_detect()	detectar patrones
str_extract()	extraer patrones
str_sub()	extraer por posición
str_length()	longitud de la cadena de caracteres

Se suelen usar expresiones regulares para patrones de caracteres. Por ejemplo, la expresión regular `[aeiou]` coincide con cualquier caracter único que sea una vocal. El uso de corchetes `[]` corresponde a clases de caracteres. Por ejemplo, `[abc]` corresponde a cada letra independientemente de la posición. `[a-z]` o `[A-Z]` o `[0-9]` cada uno entre a y z ó 0 y 9. Y por último, `[:punct:]` puntuación, etc. Con llaves "{}" podemos indicar el número del elemento anterior `{2}` sería dos veces, {1,2} entre una y dos, etc. Además con `$`o `^` podemos indicar si el patrón empieza al principio o termina al final. Podemos encontrar más detalles y patrones en el Cheat-Sheet de `stringr`.

```
# reemplazamos 'er' al final por vacío

str_replace(month.name, "er$", "")
```

```
##  [1] "January"  "February" "March"    "April"    "May"      "June"
##  [7] "July"     "August"   "Septemb"  "Octob"    "Novemb"   "Decemb"
```

```
str_replace(month.name, "^Ma", "")
```

```
##  [1] "January"   "February"  "rch"       "April"     "y"         "June"
##  [7] "July"      "August"    "September" "October"   "November"  "December"
```

```r
# combinar caracteres

a <- str_c(month.name, 1:12, sep = "_")
a
```

```
##  [1] "January_1"   "February_2"  "March_3"     "April_4"     "May_5"
##  [6] "June_6"      "July_7"      "August_8"    "September_9" "October_10"
## [11] "November_11" "December_12"
```

```r
# colapsar combinación

str_c(month.name, collapse = ", ")
```

```
## [1] "January, February, March, April, May, June, July, August, September, October, November, Decembe
```

```r
# dedectamos patrones

str_detect(a, "_[1-5]{1}")
```

```
##  [1]  TRUE  TRUE  TRUE  TRUE  TRUE FALSE FALSE FALSE FALSE  TRUE  TRUE  TRUE
```

```r
# extraemos patrones

str_extract(a, "_[1-9]{1,2}")
```

```
##  [1] "_1"  "_2"  "_3"  "_4"  "_5"  "_6"  "_7"  "_8"  "_9"  "_1"  "_11" "_12"
```

```r
# extraermos los caracteres en las posiciones entre 1 y 2

str_sub(month.name, 1, 2)
```

```
##  [1] "Ja" "Fe" "Ma" "Ap" "Ma" "Ju" "Ju" "Au" "Se" "Oc" "No" "De"
```

```r
# longitud de cada mes

str_length(month.name)
```

```
##  [1] 7 8 5 5 3 4 4 6 9 7 8 8
```

```r
# con pipe, el '.' representa al objeto que pasa el operador %>%
str_length(month.name) %>%
   str_c(month.name, ., sep = ".")
```

```
##  [1] "January.7"   "February.8"  "March.5"     "April.5"     "May.3"
##  [6] "June.4"      "July.4"      "August.6"    "September.9" "October.7"
## [11] "November.8"  "December.8"
```

Una función muy útil es `str_glue()` para interpolar caracteres.

```r
name <- c("Juan", "Michael")
age <- c(50, 80)
date_today <- Sys.Date()

str_glue(
  "My name is {name}, ",
  "I'am {age}, ",
  "and my birth year is {format(date_today-age*365, '%Y')}."
)
```

```
## My name is Juan, I'am 50, and my birth year is 1971.
```

```
## My name is Michael, I'am 80, and my birth year is 1941.
```

Manejo de fechas y horas

El paquete `lubridate` ayuda en el manejo de fechas y horas. Nos permite crear los objetos reconocidos por R con funciones (como `ymd()` ó `ymd_hms()`) y hacer cálculos.

Debemos conocer las siguientes abreviaturas:

- `ymd`: representa `y:year`, `m:month`, `d:day`
- `hms`: representa `h:hour`, `m:minutes`, `s:seconds`

```
# paquete
library(lubridate)
```

```
##
## Attaching package: 'lubridate'
```

```
## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

```
# vector de fechas
dat <- c("1999/12/31", "2000/01/07", "2005/05/20","2010/03/25")

# vector de fechas y horas
dat_time <- c("1988-08-01 05:00", "2000-02-01 22:00")

# convertir a clase date
dat <- ymd(dat)
dat
```

```
## [1] "1999-12-31" "2000-01-07" "2005-05-20" "2010-03-25"
```

```
# otras formatos
dmy("05-02-2000")
```

```
## [1] "2000-02-05"
```

```
ymd("20000506")
```

```
## [1] "2000-05-06"
```

```
# convertir a POSIXct
dat_time <- ymd_hm(dat_time)
dat_time
```

```
## [1] "1988-08-01 05:00:00 UTC" "2000-02-01 22:00:00 UTC"
```

```
# diferentes formatos en un vector
dat_mix <- c("1999/12/05", "05-09-2008", "2000/08/09", "25-10-2019")

# indicar formato con la convención conocida en ?strptime
parse_date_time(dat_mix, order = c("%Y/%m/%d", "%d-%m-%Y"))
```

```
## [1] "1999-12-05 UTC" "2008-09-05 UTC" "2000-08-09 UTC" "2019-10-25 UTC"
```

Más funciones útiles:

```
# extraer el año
year(dat)
```

```
## [1] 1999 2000 2005 2010
```

```
# el mes
month(dat)
```

```
## [1] 12  1  5  3
```

```
month(dat, label = TRUE) # como etiqueta
```

```
## [1] dic ene may mar
## 12 Levels: ene < feb < mar < abr < may < jun < jul < ago < sep < ... < dic
```

```
# el día de la semana
wday(dat)
```

```
## [1] 6 6 6 5
```

```
wday(dat, label = TRUE) # como etiqueta
```

```
## [1] vi\\. vi\\. vi\\. ju\\.
## Levels: do\\. < lu\\. < ma\\. < mi\\. < ju\\. < vi\\. < sá\\.
```

```
# la hora
hour(dat_time)
```

```
## [1]  5 22
```

```
# sumar 10 días
dat + days(10)
```

```
## [1] "2000-01-10" "2000-01-17" "2005-05-30" "2010-04-04"
```

```
# sumar 1 mes
dat + months(1)
```

```
## [1] "2000-01-31" "2000-02-07" "2005-06-20" "2010-04-25"
```

Por último, la función `make_date()` es muy útil en crear fechas a partir de diferentes partes de las mismas como puede ser el año, mes, etc.

```
# crear fecha a partir de sus elementos, aquí con año y mes
make_date(2000, 5)
```

```
## [1] "2000-05-01"
```

```
# crear fecha con hora
make_datetime(2005, 5, 23, 5)
```

```
## [1] "2005-05-23 05:00:00 UTC"
```

Podemos encontrar más detalles en el Cheat-Sheet de `lubridate`.

Manipulación de tablas y vectores

Los paquetes `dplyr` y `tidyr` nos proporciona una gramática de manipulación de datos con un conjunto de verbos útiles para resolver los problemas más comunes. Las funciones más importantes son:

Función	Descripción
mutate()	añadir nuevas variables o modificar existentes
select()	seleccionar variables
filter()	filtrar
summarise()	resumir/reducir

Función	Descripción
arrange()	ordenar
group_by()	agrupar
rename()	renombrar columnas

En caso de que no lo hayas hecho antes, importamos los datos de movilidad.

```
google_mobility <- read_csv("./datos/Global_Mobility_Report.csv")
```

```
##
## -- Column specification --------------------------------------------------------
## cols(
##   country_region_code = col_character(),
##   country_region = col_character(),
##   sub_region_1 = col_character(),
##   sub_region_2 = col_logical(),
##   iso_3166_2_code = col_character(),
##   census_fips_code = col_logical(),
##   date = col_date(format = ""),
##   retail_and_recreation_percent_change_from_baseline = col_double(),
##   grocery_and_pharmacy_percent_change_from_baseline = col_double(),
##   parks_percent_change_from_baseline = col_double(),
##   transit_stations_percent_change_from_baseline = col_double(),
##   workplaces_percent_change_from_baseline = col_double(),
##   residential_percent_change_from_baseline = col_double()
## )
```

```
## Warning: 597554 parsing failures.
##    row              col           expected         actual                                file
## 200119 sub_region_2     1/0/T/F/TRUE/FALSE Autauga County './datos/Global_Mobility_Report.csv'
## 200119 census_fips_code 1/0/T/F/TRUE/FALSE 01001          './datos/Global_Mobility_Report.csv'
## 200120 sub_region_2     1/0/T/F/TRUE/FALSE Autauga County './datos/Global_Mobility_Report.csv'
## 200120 census_fips_code 1/0/T/F/TRUE/FALSE 01001          './datos/Global_Mobility_Report.csv'
## 200121 sub_region_2     1/0/T/F/TRUE/FALSE Autauga County './datos/Global_Mobility_Report.csv'
## ...... ................ .................. ............... ...................................
## See problems(...) for more details.
```

Selecionar y renombrar

Podemos selecionar o eliminar columnas con la función `select()`, usando el nombre o índice de la(s) columna(s). Para suprimir columnas hacemos uso del signo negativo. La función `rename` ayuda en renombrar columnas o bien con el mismo nombre o con su índice.

```
residential_mobility <- select(google_mobility,
                               country_region_code:sub_region_1,
                               date,
                               residential_percent_change_from_baseline) %>%
                         rename(resi = 5)
```

Filtrar y ordenar

Para filtrar datos, empleamos `filter()` con operadores lógicos (`|`, `==`, `>`, etc) o funciones que devuelven un valor lógico (`str_detect()`, `is.na()`, etc.). La función `arrange()` ordena de menor a mayor por una o múltiples variables (con el signo negativo `-` se invierte el orden de mayor a menor).

```
filter(residential_mobility,
       country_region_code == "US")
```

```
## # A tibble: 304,648 x 5
##    country_region_code country_region sub_region_1 date        resi
##    <chr>               <chr>          <chr>        <date>     <dbl>
##  1 US                  United States  <NA>         2020-02-15    -1
##  2 US                  United States  <NA>         2020-02-16    -1
##  3 US                  United States  <NA>         2020-02-17     5
##  4 US                  United States  <NA>         2020-02-18     1
##  5 US                  United States  <NA>         2020-02-19     0
##  6 US                  United States  <NA>         2020-02-20     1
##  7 US                  United States  <NA>         2020-02-21     0
##  8 US                  United States  <NA>         2020-02-22    -1
##  9 US                  United States  <NA>         2020-02-23    -1
## 10 US                  United States  <NA>         2020-02-24     0
## # ... with 304,638 more rows
```

```
filter(residential_mobility,
       country_region_code == "US",
       sub_region_1 == "New York")
```

```
## # A tibble: 7,068 x 5
##    country_region_code country_region sub_region_1 date        resi
##    <chr>               <chr>          <chr>        <date>     <dbl>
##  1 US                  United States  New York     2020-02-15     0
##  2 US                  United States  New York     2020-02-16    -1
##  3 US                  United States  New York     2020-02-17     9
##  4 US                  United States  New York     2020-02-18     3
##  5 US                  United States  New York     2020-02-19     2
##  6 US                  United States  New York     2020-02-20     2
##  7 US                  United States  New York     2020-02-21     3
##  8 US                  United States  New York     2020-02-22    -1
##  9 US                  United States  New York     2020-02-23    -1
## 10 US                  United States  New York     2020-02-24     0
## # ... with 7,058 more rows
```

```
filter(residential_mobility,
       resi > 50) %>%
          arrange(-resi)
```

```
## # A tibble: 32 x 5
##    country_region_co~ country_region sub_region_1               date        resi
##    <chr>              <chr>          <chr>                      <date>     <dbl>
##  1 KW                 Kuwait         Al Farwaniyah Governorate  2020-05-14    56
##  2 KW                 Kuwait         Al Farwaniyah Governorate  2020-05-21    55
##  3 SG                 Singapore      <NA>                       2020-05-01    55
##  4 KW                 Kuwait         Al Farwaniyah Governorate  2020-05-28    54
##  5 PE                 Peru           Metropolitan Municipality~ 2020-04-10    54
##  6 EC                 Ecuador        Pichincha                  2020-03-27    53
##  7 KW                 Kuwait         Al Farwaniyah Governorate  2020-05-11    53
##  8 KW                 Kuwait         Al Farwaniyah Governorate  2020-05-13    53
##  9 KW                 Kuwait         Al Farwaniyah Governorate  2020-05-20    53
## 10 SG                 Singapore      <NA>                       2020-04-10    53
## # ... with 22 more rows
```

Agrupar y resumir

¿Dónde encontramos mayor variabilidad entre regiones en cada país el día 1 de abril de 2020?

Para responder a esta pregunta, primero filtramos los datos y después agrupamos por la columna de país. Cuando empleamos la función `summarise()` posterior a la agrupación, nos permite resumir por estos grupos. Incluso, la combinación del `group_by()` con la función `mutate()` permite modificar columnas por grupos. En `summarise()` calculamos el valor máximo, mínimo y la diferencia entre ambos extremos creando nuevas columnas.

```
resi_variability <- residential_mobility %>%
                        filter(date == ymd("2020-04-01"),
                               !is.na(sub_region_1)) %>%
                          group_by(country_region) %>%
                             summarise(mx = max(resi, na.rm = TRUE),
                                       min = min(resi, na.rm = TRUE),
                                       range = abs(mx)-abs(min))

arrange(resi_variability, -range)
```

```
## # A tibble: 94 x 4
##    country_region    mx   min range
##    <chr>          <dbl> <dbl> <dbl>
##  1 Nigeria           43     6    37
##  2 United States     35     6    29
##  3 India             36    15    21
##  4 Malaysia          45    26    19
##  5 Philippines       40    21    19
##  6 Vietnam           28     9    19
##  7 Colombia          41    24    17
##  8 Ecuador           44    27    17
##  9 Argentina         35    19    16
## 10 Chile             30    14    16
## # ... with 84 more rows
```

Unir tablas

¿Cómo podemos filtrar los datos para obtener un subconjunto de Europa?

Para ello, importamos datos espaciales con el código de país y una columna de las regiones usando el paquete `sf` (*simple feature*).

```
library(rnaturalearth) # paquete de datos vectoriales

# datos de países
wld <- ne_countries(returnclass = "sf")

# filtramos los países con código y seleccionamos las dos columnas de interés
wld <- filter(wld, !is.na(iso_a2)) %>% select(iso_a2, subregion)

# plot
plot(wld)
```

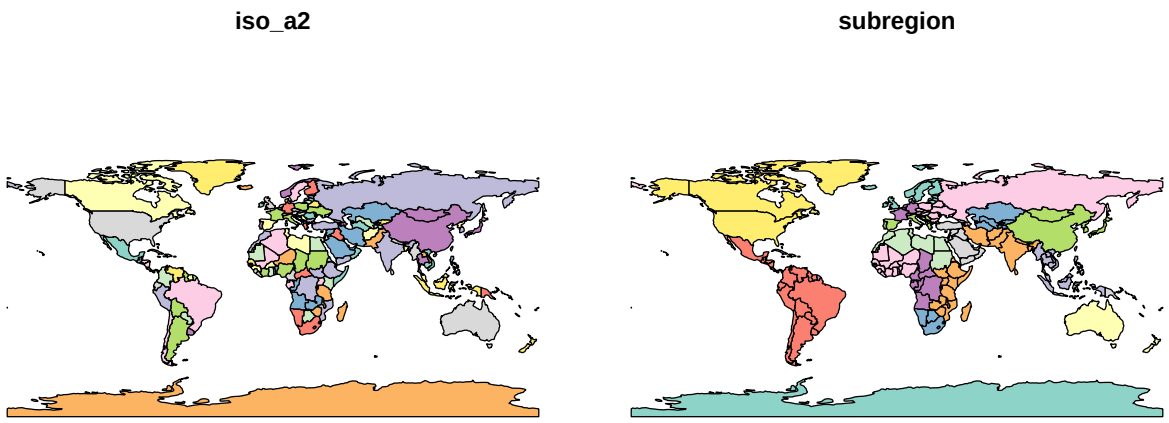

Otras funciones de `dplyr` nos permiten unir tablas: `*_join()`. Según hacia qué tabla (izquierda o derecha) se quiere unir, cambia la función : `left_join()`, `right_join()` o incluso `full_join()`. El argumento `by` no es necesario siempre y cuando ambas tablas tienen una columna en común. No obstante, en este caso la columna de fusión es diferente, por eso, usamos el modo `c("country_region_code"="iso_a2")`. El paquete `forcats` de `tidyverse` tiene muchas funciones útiles para manejar variables categóricas (`factors`), variables que tienen un conjunto fijo y conocido de valores posibles. Todas las funciones de `forcats` tienen el prefijo `fct_*`. Por ejemplo, en este caso usamos `fct_reorder()` para reordenar las etiquetas de los países en orden de la máxima basada en los registros de movibilidad residencial. Finalmente, creamos una nueva columna 'resi_real' para cambiar el valor de referencia, el promedio (*baseline*), fijado en 0 a 100.

```
subset_europe <- filter(residential_mobility,
                        is.na(sub_region_1),
                        !is.na(resi)) %>%
                 left_join(wld, by = c("country_region_code"="iso_a2")) %>%
                 filter(subregion %in% c("Northern Europe",
                                         "Southern Europe",
                                          "Western Europe",
                                          "Eastern Europe")) %>%
                 mutate(resi_real = resi + 100,
                        region = fct_reorder(country_region,
                                             resi,
                                             .fun = "max",
                                             .desc = FALSE)) %>%
                select(-geometry, -sub_region_1)

str(subset_europe)
```

```
## tibble [3,988 x 7] (S3: tbl_df/tbl/data.frame)
##  $ country_region_code: chr [1:3988] "AT" "AT" "AT" "AT" ...
##  $ country_region     : chr [1:3988] "Austria" "Austria" "Austria" "Austria" ...
##  $ date               : Date[1:3988], format: "2020-02-15" "2020-02-16" ...
##  $ resi               : num [1:3988] -2 -2 0 0 1 0 1 -2 0 -1 ...
##  $ subregion          : chr [1:3988] "Western Europe" "Western Europe" "Western Europe" "Western Eur
##  $ resi_real          : num [1:3988] 98 98 100 100 101 100 101 98 100 99 ...
##  $ region             : Factor w/ 35 levels "Belarus","Ukraine",..: 18 18 18 18 18 18 18 18 18 18 ..
##  - attr(*, "problems")= tibble [597,554 x 5] (S3: tbl_df/tbl/data.frame)
```

```
##   ..$ row     : int [1:597554] 200119 200119 200120 200120 200121 200121 200122 200122 200123 200123
##   ..$ col     : chr [1:597554] "sub_region_2" "census_fips_code" "sub_region_2" "census_fips_code" .
##   ..$ expected: chr [1:597554] "1/0/T/F/TRUE/FALSE" "1/0/T/F/TRUE/FALSE" "1/0/T/F/TRUE/FALSE" "1/0/T/
##   ..$ actual  : chr [1:597554] "Autauga County" "01001" "Autauga County" "01001" ...
##   ..$ file    : chr [1:597554] "'./datos/Global_Mobility_Report.csv'" "'./datos/Global_Mobility_Repo
```

Tablas largas y anchas

Antes de pasar a la visualización con `ggplot2`. Es muy habitual modificar la tabla entre dos formatos principales. Una tabla es *tidy* cuando 1) cada variable es una columna 2) cada observación/caso es una fila y 3) cada tipo de unidad observacional forma una tabla.

```
# subconjunto
mobility_selection <- select(subset_europe, country_region_code, date:resi)
mobility_selection
```

```
## # A tibble: 3,988 x 3
##    country_region_code date        resi
##    <chr>               <date>     <dbl>
##  1 AT                  2020-02-15    -2
##  2 AT                  2020-02-16    -2
##  3 AT                  2020-02-17     0
##  4 AT                  2020-02-18     0
##  5 AT                  2020-02-19     1
##  6 AT                  2020-02-20     0
##  7 AT                  2020-02-21     1
##  8 AT                  2020-02-22    -2
##  9 AT                  2020-02-23     0
## 10 AT                  2020-02-24    -1
## # ... with 3,978 more rows
```

```
# tabla ancha
mobi_wide <- pivot_wider(mobility_selection,
                         names_from = country_region_code,
                         values_from = resi)
mobi_wide
```

```
## # A tibble: 114 x 36
##    date          AT    BA    BE    BG    BY    CH    CZ    DE    DK    EE    ES
##    <date>     <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
##  1 2020-02-15    -2    -1    -1     0    -1    -1    -2    -1     0     0    -2
##  2 2020-02-16    -2    -1     1    -3     0    -1    -1     0     1     0    -2
##  3 2020-02-17     0    -1     0    -2     0     1     0     0     1     1    -1
##  4 2020-02-18     0    -1     0    -2     0     1     0     1     1     1     0
##  5 2020-02-19     1    -1     0    -1    -1     1     0     1     1     0    -1
##  6 2020-02-20     0    -1     0     0    -1     0     0     1     1     0    -1
##  7 2020-02-21     1    -2     0    -1    -1     1     0     2     1     1    -2
##  8 2020-02-22    -2    -1     0     0    -2    -2    -3     0     1     0    -2
##  9 2020-02-23     0    -1     0    -3    -1    -1     0     0     0    -2    -3
## 10 2020-02-24    -1    -1     4    -1     0     0     0     4     0    16     0
## # ... with 104 more rows, and 24 more variables: FI <dbl>, FR <dbl>, GB <dbl>,
## #   GR <dbl>, HR <dbl>, HU <dbl>, IE <dbl>, IT <dbl>, LT <dbl>, LU <dbl>,
## #   LV <dbl>, MD <dbl>, MK <dbl>, NL <dbl>, NO <dbl>, PL <dbl>, PT <dbl>,
## #   RO <dbl>, RS <dbl>, RU <dbl>, SE <dbl>, SI <dbl>, SK <dbl>, UA <dbl>
```

```r
# tabla larga
pivot_longer(mobi_wide,
             2:36,
             names_to = "country_code",
             values_to = "resi")
```

```
## # A tibble: 3,990 x 3
##    date       country_code  resi
##    <date>     <chr>        <dbl>
##  1 2020-02-15 AT              -2
##  2 2020-02-15 BA              -1
##  3 2020-02-15 BE              -1
##  4 2020-02-15 BG               0
##  5 2020-02-15 BY              -1
##  6 2020-02-15 CH              -1
##  7 2020-02-15 CZ              -2
##  8 2020-02-15 DE              -1
##  9 2020-02-15 DK               0
## 10 2020-02-15 EE               0
## # ... with 3,980 more rows
```

Otro grupo de funciones a las que deberías echar un vistazo son: `separate()`, `case_when()`, `complete()`. Podemos encontrar más detalles en el Cheat-Sheet de `dplyr`

Series temporales

El paquete `tsibble` proporciona una infraestructura de datos para datos temporales ordenados (*tidy*). Adaptando los principios de datos ordenados, `tsibble` es un objeto orientado a datos y modelos. En `tsibble` podemos indicar el índice de una variable temporal, diferentes variables que definen las observaciones (cada observación debe ser identificada de forma única con el índice y la(s) variable(s)), y cada unidad de observación puede un intervalo regular o irregular.

En este ejemplo, haremos uso de un subset del número diario de recetas de varias ciudades españolas agrupado por el Sistema de Clasificación Anatómica, Terapéutica, Química (ATC).

```r
# paquete
library(tsibble)
```

```
##
## Attaching package: 'tsibble'
```

```
## The following object is masked from 'package:lubridate':
##
##     interval
```

```
## The following objects are masked from 'package:base':
##
##     intersect, setdiff, union
```

```r
# cargar datos
load("./datos/datos_ts.RData")

# estructura
str(recetas_all)
```

```
## 'data.frame':    8701 obs. of  4 variables:
##  $ ciudad     : chr  "MADRID" "MADRID" "MADRID" "MADRID" ...
##  $ fecha_pres : Date, format: "2004-01-02" "2004-01-05" ...
```

```
##  $ atc2_codigo: chr  "R01" "R01" "R01" "R01" ...
##  $ n          : int  74 76 82 69 65 79 88 96 77 79 ...
```

Para convertir un `data.frame` o `tibble` en un `tsibble` debemos indicar las variables que componen cada observación y la columan con el índice temporal.

```
# load package
recetas_all <- tsibble(recetas_all, key = c("ciudad", "atc2_codigo"), index = "fecha_pres")

# clase
class(recetas_all)
```

```
## [1] "tbl_ts"     "tbl_df"     "tbl"        "data.frame"
```

Una vez que tenemos la clase `tsibble` es posible aplicar diferentes funciones para conocer si tenemos filas dublicadas o lagunas, e incluso podemos rellenar valores ausentes.

```
# filas dublicadas
is_duplicated(recetas_all, key = c("ciudad", "atc2_codigo")) # are_dublicated()
```

```
## Using `fecha_pres` as index variable.
```

```
## [1] FALSE
```

```
# lagunas?
has_gaps(recetas_all)
```

```
## # A tibble: 28 x 3
##    ciudad atc2_codigo .gaps
##    <chr>  <chr>       <lgl>
##  1 MADRID R01         TRUE
##  2 MADRID R02         TRUE
##  3 MADRID R03         TRUE
##  4 MADRID R05         TRUE
##  5 MADRID R06         TRUE
##  6 MADRID R07         TRUE
##  7 MURCIA R01         TRUE
##  8 MURCIA R02         TRUE
##  9 MURCIA R03         FALSE
## 10 MURCIA R05         TRUE
## # ... with 18 more rows
```

```
count_gaps(recetas_all)
```

```
## # A tibble: 1,701 x 5
##    ciudad atc2_codigo .from      .to           .n
##    <chr>  <chr>       <date>     <date>     <int>
##  1 MADRID R01         2004-01-03 2004-01-04     2
##  2 MADRID R01         2004-01-06 2004-01-06     1
##  3 MADRID R01         2004-01-10 2004-01-11     2
##  4 MADRID R01         2004-01-18 2004-01-18     1
##  5 MADRID R01         2004-01-25 2004-01-25     1
##  6 MADRID R01         2004-02-01 2004-02-01     1
##  7 MADRID R01         2004-02-08 2004-02-08     1
##  8 MADRID R01         2004-02-15 2004-02-15     1
##  9 MADRID R01         2004-02-21 2004-02-22     2
## 10 MADRID R01         2004-02-29 2004-02-29     1
## # ... with 1,691 more rows
```

```
# llenar lagunas
recetas_all <- recetas_all %>%
                  fill_gaps(n = 0)
```

También nos permite resumir por diferentes unidades temporales basado en el índice.

```
recetas_all %>%
 group_by_key() %>%
  index_by(year_month = ~ yearmonth(.)) %>%
   summarise(n = sum(n))
```

```
## # A tsibble: 869 x 4 [1M]
## # Key:       ciudad, atc2_codigo [28]
## # Groups:    ciudad [5]
##    ciudad atc2_codigo year_month     n
##    <chr>  <chr>            <mth> <dbl>
##  1 MADRID R01          2004 ene.  1722
##  2 MADRID R01          2004 feb.  1793
##  3 MADRID R01          2004 mar.  1866
##  4 MADRID R01          2004 abr.  1873
##  5 MADRID R01          2004 may.  2070
##  6 MADRID R01          2004 jun.  2346
##  7 MADRID R01          2004 jul.   900
##  8 MADRID R01          2004 ago.   641
##  9 MADRID R01          2004 sep.  1522
## 10 MADRID R01          2004 oct.  1878
## # ... with 859 more rows
```

Para finalizar añadimos algunas variables nuevas.

```
recetas_all <- recetas_all %>%
                arrange(ciudad, atc2_codigo, fecha_pres) %>%
                  group_by(ciudad, atc2_codigo) %>%
                    mutate(trend = row_number(),
                           dow = wday(fecha_pres, label = TRUE),
                           yy = year(fecha_pres),
                           mm = month(fecha_pres),
                           dd = day(fecha_pres),
                           ciudad = str_to_lower(ciudad))


str(recetas_all)
```

```
## grouped_ts [26,085 x 9] (S3: grouped_ts/grouped_df/tbl_ts/tbl_df/tbl/data.frame)
##  $ ciudad     : chr [1:26085] "madrid" "madrid" "madrid" "madrid" ...
##  $ fecha_pres : Date[1:26085], format: "2004-01-02" "2004-01-03" ...
##  $ atc2_codigo: chr [1:26085] "R01" "R01" "R01" "R01" ...
##  $ n          : num [1:26085] 74 0 0 76 0 82 69 65 0 0 ...
##  $ trend      : int [1:26085] 1 2 3 4 5 6 7 8 9 10 ...
##  $ dow        : Ord.factor w/ 7 levels "do\\."<"lu\\."<..: 6 7 1 2 3 4 5 6 7 1 ...
##  $ yy         : num [1:26085] 2004 2004 2004 2004 2004 ...
##  $ mm         : num [1:26085] 1 1 1 1 1 1 1 1 1 1 ...
##  $ dd         : int [1:26085] 2 3 4 5 6 7 8 9 10 11 ...
##  - attr(*, "key")= tibble [28 x 3] (S3: tbl_df/tbl/data.frame)
##   ..$ ciudad     : chr [1:28] "madrid" "madrid" "madrid" "madrid" ...
##   ..$ atc2_codigo: chr [1:28] "R01" "R02" "R03" "R05" ...
```

```
##   ..$ .rows      : list<int> [1:28]
##   .. ..$ : int [1:511] 1 2 3 4 5 6 7 8 9 10 ...
##   .. ..$ : int [1:3904] 512 513 514 515 516 517 518 519 520 521 ...
##   .. ..$ : int [1:509] 4416 4417 4418 4419 4420 4421 4422 4423 4424 4425 ...
##   .. ..$ : int [1:497] 4925 4926 4927 4928 4929 4930 4931 4932 4933 4934 ...
##   .. ..$ : int [1:504] 5422 5423 5424 5425 5426 5427 5428 5429 5430 5431 ...
##   .. ..$ : int [1:1758] 5926 5927 5928 5929 5930 5931 5932 5933 5934 5935 ...
##   .. ..$ : int [1:375] 7684 7685 7686 7687 7688 7689 7690 7691 7692 7693 ...
##   .. ..$ : int [1:991] 8059 8060 8061 8062 8063 8064 8065 8066 8067 8068 ...
##   .. ..$ : int [1:365] 9050 9051 9052 9053 9054 9055 9056 9057 9058 9059 ...
##   .. ..$ : int [1:372] 9415 9416 9417 9418 9419 9420 9421 9422 9423 9424 ...
##   .. ..$ : int [1:365] 9787 9788 9789 9790 9791 9792 9793 9794 9795 9796 ...
##   .. ..$ : int 10152
##   .. ..$ : int [1:365] 10153 10154 10155 10156 10157 10158 10159 10160 10161 10162 ...
##   .. ..$ : int [1:3434] 10518 10519 10520 10521 10522 10523 10524 10525 10526 10527 ...
##   .. ..$ : int [1:365] 13952 13953 13954 13955 13956 13957 13958 13959 13960 13961 ...
##   .. ..$ : int [1:365] 14317 14318 14319 14320 14321 14322 14323 14324 14325 14326 ...
##   .. ..$ : int [1:365] 14682 14683 14684 14685 14686 14687 14688 14689 14690 14691 ...
##   .. ..$ : int [1:1754] 15047 15048 15049 15050 15051 15052 15053 15054 15055 15056 ...
##   .. ..$ : int [1:481] 16801 16802 16803 16804 16805 16806 16807 16808 16809 16810 ...
##   .. ..$ : int [1:482] 17282 17283 17284 17285 17286 17287 17288 17289 17290 17291 ...
##   .. ..$ : int [1:447] 17764 17765 17766 17767 17768 17769 17770 17771 17772 17773 ...
##   .. ..$ : int [1:476] 18211 18212 18213 18214 18215 18216 18217 18218 18219 18220 ...
##   .. ..$ : int [1:425] 18687 18688 18689 18690 18691 18692 18693 18694 18695 18696 ...
##   .. ..$ : int [1:798] 19112 19113 19114 19115 19116 19117 19118 19119 19120 19121 ...
##   .. ..$ : int [1:389] 19910 19911 19912 19913 19914 19915 19916 19917 19918 19919 ...
##   .. ..$ : int [1:421] 20299 20300 20301 20302 20303 20304 20305 20306 20307 20308 ...
##   .. ..$ : int [1:407] 20720 20721 20722 20723 20724 20725 20726 20727 20728 20729 ...
##   .. ..$ : int [1:4959] 21127 21128 21129 21130 21131 21132 21133 21134 21135 21136 ...
##   .. ..@ ptype: int(0)
##   ..- attr(*, ".drop")= logi TRUE
##  - attr(*, "index")= chr "fecha_pres"
##   ..- attr(*, "ordered")= logi TRUE
##  - attr(*, "index2")= chr "fecha_pres"
##  - attr(*, "interval")= interval [1:1] 1D
##   ..@ .regular: logi TRUE
##  - attr(*, "groups")= tibble [28 x 3] (S3: tbl_df/tbl/data.frame)
##   ..$ ciudad     : chr [1:28] "madrid" "madrid" "madrid" "madrid" ...
##   ..$ atc2_codigo: chr [1:28] "R01" "R02" "R03" "R05" ...
##   ..$ .rows      : list<int> [1:28]
##   .. ..$ : int [1:511] 1 2 3 4 5 6 7 8 9 10 ...
##   .. ..$ : int [1:3904] 512 513 514 515 516 517 518 519 520 521 ...
##   .. ..$ : int [1:509] 4416 4417 4418 4419 4420 4421 4422 4423 4424 4425 ...
##   .. ..$ : int [1:497] 4925 4926 4927 4928 4929 4930 4931 4932 4933 4934 ...
##   .. ..$ : int [1:504] 5422 5423 5424 5425 5426 5427 5428 5429 5430 5431 ...
##   .. ..$ : int [1:1758] 5926 5927 5928 5929 5930 5931 5932 5933 5934 5935 ...
##   .. ..$ : int [1:375] 7684 7685 7686 7687 7688 7689 7690 7691 7692 7693 ...
##   .. ..$ : int [1:991] 8059 8060 8061 8062 8063 8064 8065 8066 8067 8068 ...
##   .. ..$ : int [1:365] 9050 9051 9052 9053 9054 9055 9056 9057 9058 9059 ...
##   .. ..$ : int [1:372] 9415 9416 9417 9418 9419 9420 9421 9422 9423 9424 ...
##   .. ..$ : int [1:365] 9787 9788 9789 9790 9791 9792 9793 9794 9795 9796 ...
##   .. ..$ : int 10152
##   .. ..$ : int [1:365] 10153 10154 10155 10156 10157 10158 10159 10160 10161 10162 ...
##   .. ..$ : int [1:3434] 10518 10519 10520 10521 10522 10523 10524 10525 10526 10527 ...
```

```
##   .. ..$ : int [1:365] 13952 13953 13954 13955 13956 13957 13958 13959 13960 13961 ...
##   .. ..$ : int [1:365] 14317 14318 14319 14320 14321 14322 14323 14324 14325 14326 ...
##   .. ..$ : int [1:365] 14682 14683 14684 14685 14686 14687 14688 14689 14690 14691 ...
##   .. ..$ : int [1:1754] 15047 15048 15049 15050 15051 15052 15053 15054 15055 15056 ...
##   .. ..$ : int [1:481] 16801 16802 16803 16804 16805 16806 16807 16808 16809 16810 ...
##   .. ..$ : int [1:482] 17282 17283 17284 17285 17286 17287 17288 17289 17290 17291 ...
##   .. ..$ : int [1:447] 17764 17765 17766 17767 17768 17769 17770 17771 17772 17773 ...
##   .. ..$ : int [1:476] 18211 18212 18213 18214 18215 18216 18217 18218 18219 18220 ...
##   .. ..$ : int [1:425] 18687 18688 18689 18690 18691 18692 18693 18694 18695 18696 ...
##   .. ..$ : int [1:798] 19112 19113 19114 19115 19116 19117 19118 19119 19120 19121 ...
##   .. ..$ : int [1:389] 19910 19911 19912 19913 19914 19915 19916 19917 19918 19919 ...
##   .. ..$ : int [1:421] 20299 20300 20301 20302 20303 20304 20305 20306 20307 20308 ...
##   .. ..$ : int [1:407] 20720 20721 20722 20723 20724 20725 20726 20727 20728 20729 ...
##   .. ..$ : int [1:4959] 21127 21128 21129 21130 21131 21132 21133 21134 21135 21136 ...
##   .. ..@ ptype: int(0)
##   ..- attr(*, ".drop")= logi TRUE
```

El paquete `feasts` facilita a partir de la clase `tsibble` la aplicaciónde una descomposicón temporal o alguna visualización exploratoria.

Visualizar datos

`ggplot2` es un sistema moderno, y con una enorme variedad de opciones, para visualización de datos. A diferencia del sistema gráfico de *R Base* se utiliza una gramática diferente. La gramática de los gráficos (*grammar of graphics*, de allí "gg") consiste en la suma de varias capas u objetos independientes que se combinan usando `+` para construir el gráfico final. `ggplot` diferencia entre los datos, lo que se visualiza y la forma en que se visualiza.

- *data*: nuestro conjunto de datos (`data.frame` o `tibble`)
- *aesthetics*: con la función `aes()` indicamos las variables que corresponden a los ejes x, y, z,... o, cuando se pretende aplicar parámetros gráficos (*color*, *size*, *shape*) según una variable. Es posible incluir `aes()` en `ggplot()` o en la función correspondiente a una geometría `geom_*`.
- *geometries*: son objetos `geom_*` que indican la geometría a usar, (p. ej.: `geom_point()`, `geom_line()`, `geom_boxplot()`, etc.).
- *scales*: son objetos de tipo `scales_*` (p. ej.: `scale_x_continous()`, `scale_colour_manual()`) para manipular las ejes, definir colores, etc.
- *statistics*: son objetos `stat_*` (p.ej.: `stat_density()`) que permiten aplicar transformaciones estadísticas.

Podemos encontrar más detalles en el Cheat-Sheet de `ggplot2`. `ggplot` es complementado constantemente con extensiones para geometrías u otras opciones gráficas (https://exts.ggplot2.tidyverse.org/ggiraph.html), para obtener ideas gráficas, debes echarle un vistazo a la Galería de Gráficos R (https://www.r-graph-gallery.com/).

Gráfico de linea y puntos

Creamos un subconjunto de nuestros datos de movilidad para residencias y parques, filtrando los registros de regiones italianas. Además, dividimos los valores de movilidad en porcentaje por 100 para obtener la fracción, ya que `ggplot2` nos permite indicar la unidad de porcentaje en el argumento de las etiquetas (último gráfico de esta sección).

```
# creamos el subconjunto
it <- filter(google_mobility,
             country_region == "Italy",
             is.na(sub_region_1)) %>%
```

```
      mutate(resi = residential_percent_change_from_baseline/100,
             parks = parks_percent_change_from_baseline/100)


# gráfico de línea
ggplot(it,
       aes(date, resi)) +
  geom_line()
```

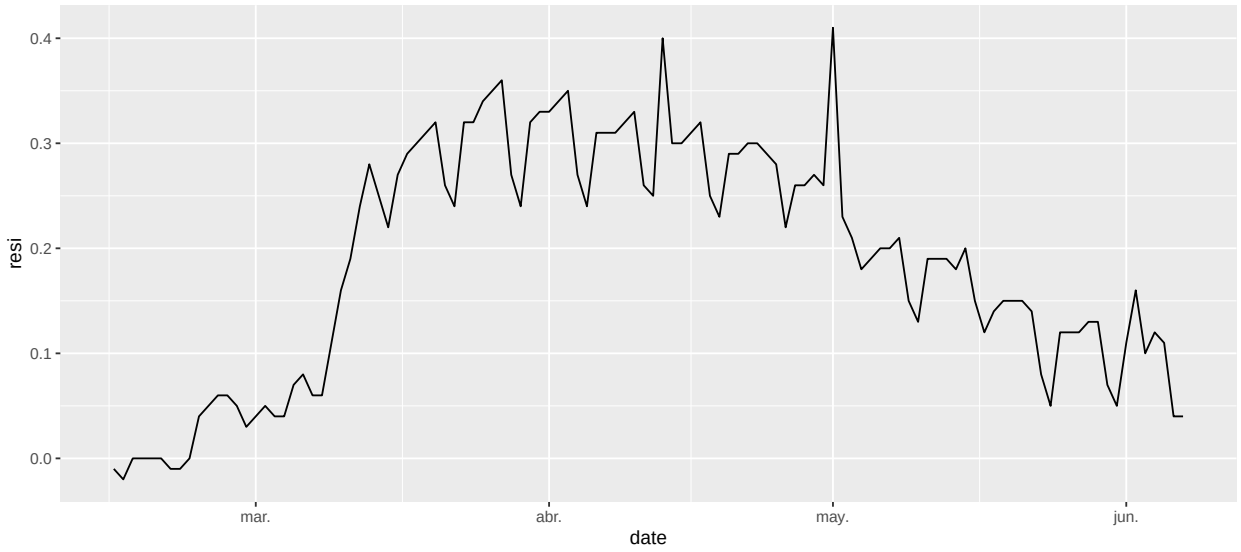


```
# gráfico de dispersión con línea de correlación
ggplot(it,
       aes(parks, resi)) +
  geom_point() +
  geom_smooth(method = "lm")
```

```
## `geom_smooth()` using formula 'y ~ x'
```

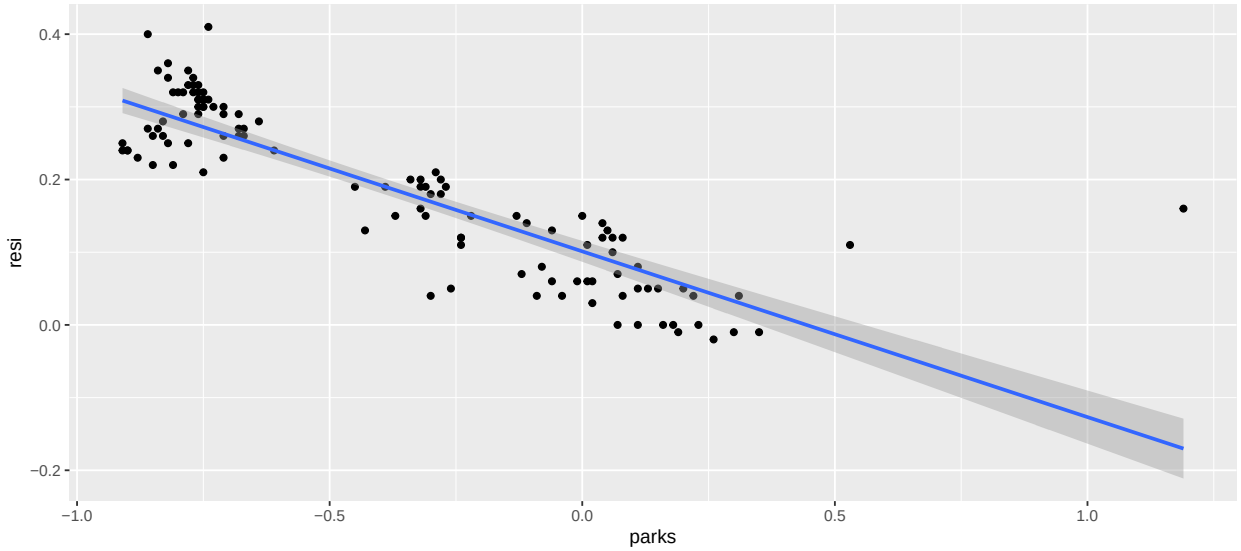

Para modificar los ejes, empleamos las diferentes funciones de `scale_*` que debemos adpatar a las escalas de

medición (*date*, *discrete*, *continuous*, etc.). La función `labs()` nos ayuda en definir los títulos de ejes, del gráfico y de la leyenda. Por último, añadimos con `theme_light()` el estilo del gráfico (otros son `theme_bw()`, `theme_minimal()`, etc.). También podríamos hacer cambios de todos los elementos gráficos a través de `theme()`.

```
# time serie plot
ggplot(it,
       aes(date, resi)) +
  geom_line(colour = "#560A86", size = 0.8) +
  scale_x_date(date_breaks = "10 days",
               date_labels = "%d %b") +
  scale_y_continuous(breaks = seq(-0.1, 1, 0.1),
                     labels = scales::percent) +
  labs(x = "",
       y = "Residential mobility",
       title = "Mobility during COVID-19") +
  theme_light()
```

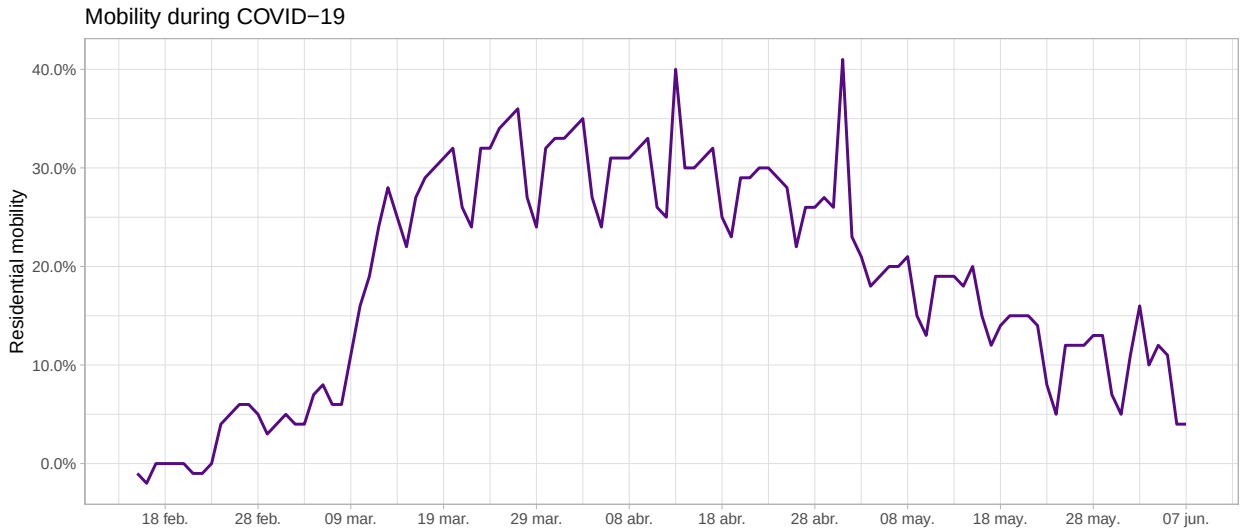


```
# scatter plot
ggplot(it,
       aes(parks, resi)) +
  geom_point(alpha = .4, size = 2) +
  geom_smooth(method = "lm") +
  scale_x_continuous(breaks = seq(-1, 1.4, 0.2),
                     labels = scales::percent) +
  scale_y_continuous(breaks = seq(-1, 1, 0.1),
                     labels = scales::percent) +
  labs(x = "Park mobility",
       y = "Residential mobility",
       title = "Mobility during COVID-19") +
  theme_light()
```

```
## `geom_smooth()` using formula 'y ~ x'
```

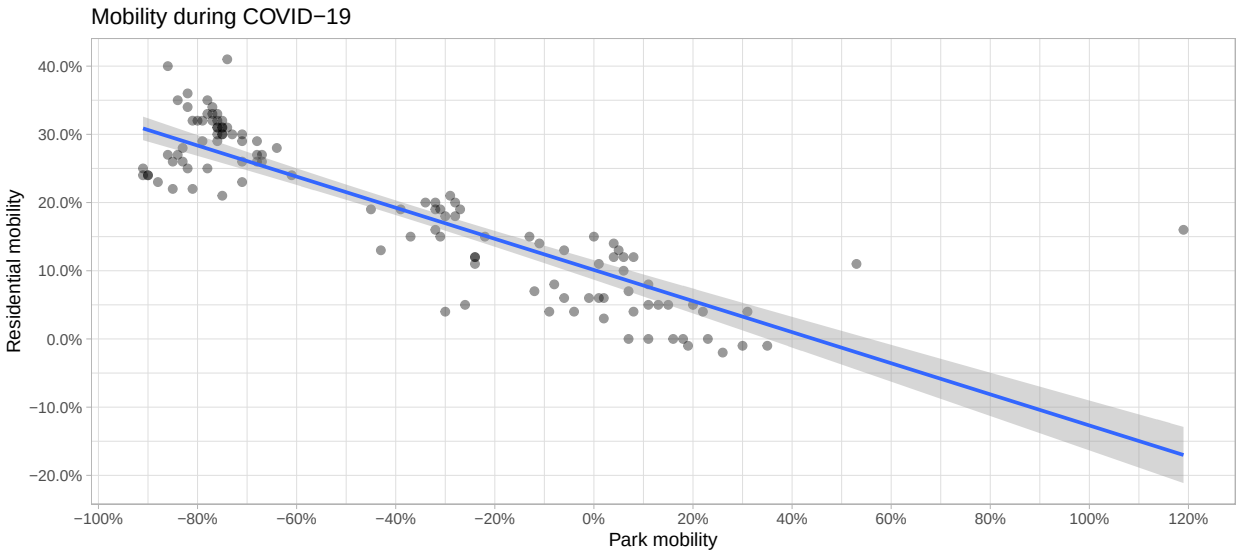

Boxplot

Podemos visualizar diferentes aspectos de los datos de movilidad con otras geometrías. Aquí creamos *boxplots* por cada país europeo representando la variabilidad de movilidad entre y en los países durante la pandemia del COVID-19.

```
# subconjunto
subset_europe_reg <- filter(residential_mobility,
                            !is.na(sub_region_1),
                            !is.na(resi)) %>%
                     left_join(wld, by = c("country_region_code"="iso_a2")) %>%
                     filter(subregion %in% c("Northern Europe",
                                             "Southern Europe",
                                              "Western Europe",
                                              "Eastern Europe")) %>%
                     mutate(resi = resi/100,
                            country_region = fct_reorder(country_region, resi))

# boxplot
ggplot(subset_europe_reg,
       aes(country_region, resi, fill = subregion)) +
  geom_boxplot() +
  scale_y_continuous(breaks = seq(-0.1, 1, 0.1), labels = scales::percent) +
  scale_fill_brewer(palette = "Set1") +
  coord_flip() +
   labs(x = "",
       y = "Residential mobility",
       title = "Mobility during COVID-19",
       fill = "") +
  theme_minimal()
```

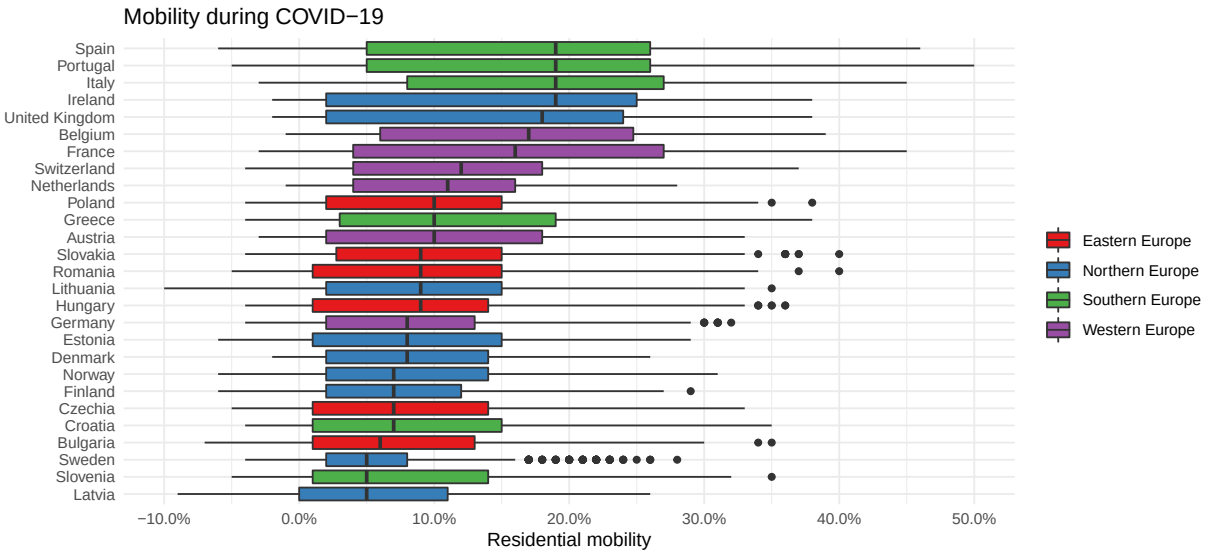

Heatmap

Para visualizar la tendencia de todos los países europeos es recomendable usar un *heatmap* en lugar de un bulto de líneas. Antes de constuir el gráfico, creamos un vector de fechas para las etiquetas con los domingos en el período de registros.

```
# secuencia de fechas
df <- data.frame(d = seq(ymd("2020-02-15"), ymd("2020-06-07"), "day"))

# filtramos los domingos creando el día de la semana
sundays <- df %>%
            mutate(wd = wday(d, week_start = 1)) %>%
             filter(wd == 7) %>%
              pull(d)
```

Si queremos usar etiquetas en otras lenguas, es necesario cambiar la configuración regional del sistema.

```
Sys.setlocale("LC_TIME", "English")
```

```
## [1] "English_United States.1252"
```

El relleno de color para los boxplots lo dibujamos por cada región de los países europeos. Podemos fijar el tipo de color con `scale_fill_*`, en este caso, de las gamas *viridis*.
Además, la función `guides()` nos permite modificar la barra de color de la leyenda. Por último, aquí vemos el uso de `theme()` con cambios adicionales a `theme_minimal()`.

```
# headmap
ggplot(subset_europe,
       aes(date, region, fill = resi_real)) +
  geom_tile() +
  scale_x_date(breaks = sundays,
               date_labels = "%d %b") +
  scale_fill_viridis_c(option = "A",
                       breaks = c(91, 146),
                       labels = c("Less", "More"),
                       direction = -1) +
  theme_minimal() +
  theme(legend.position = "top",
```

```
        title = element_text(size = 14),
        panel.grid.major.x = element_line(colour = "white", linetype = "dashed"),
        panel.grid.minor.x = element_blank(),
        panel.grid.major.y = element_blank(),
        panel.ontop = TRUE,
        plot.margin = margin(r = 1, unit = "cm")) +
  labs(y = "",
       x = "",
       fill = "",
       title = "Mobility trends for places of residence",
       caption = "Data: google.com/covid19/mobility/") +
  guides(fill = guide_colorbar(barwidth = 10,
                               barheight = .5,
                               label.position = "top",
                               ticks = FALSE)) +
  coord_cartesian(expand = FALSE)
```

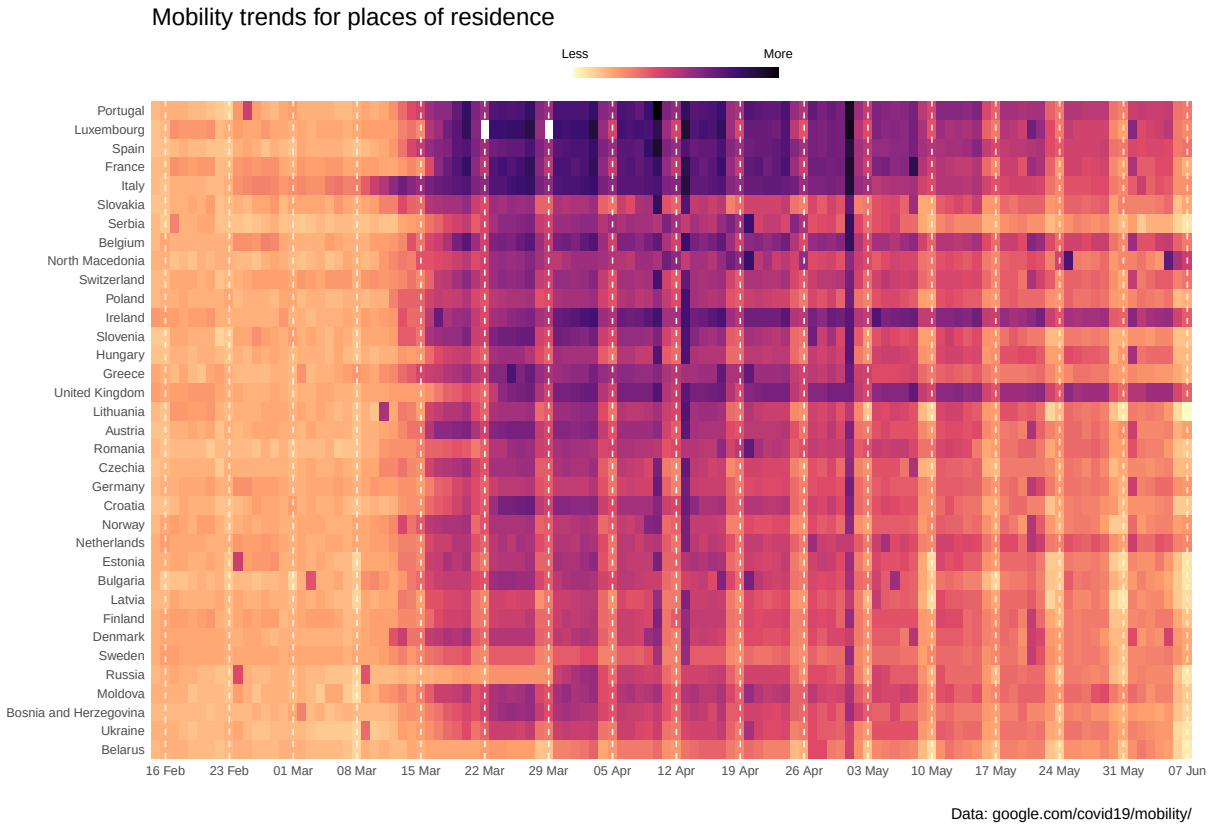

Gráficos de incertidumbre

En este apartado nos concentramos en gráficos de intercertidumbre representados por líneas con intervalo de confianza y en rangos de línea con puntos. Los datos que usamos aquí provienen de los resultados obtenidos en Iñiguez et al (2021).

Primero cargamos varios paquetes adicionales para importar los datos en formato Stata (.dta), adicionales estilos de gráfico y funciones auxilares de visualización. En el segundo paso, creamos varias variables a partir de de la columna *outcome* con el fin de poder separar por un lado la mortalidad y los ingresos hospitalarios, y por otro, las causas respiratorias y cardiovasculares. En general, cuando trabajamos con tidyverse debemos conseguir una tabla *tidy*, o sea, cada variable es una columna, cada observación/caso es una fila y cada tipo

de unidad observacional forma una tabla.

```
# paquetes

library(foreign)
library(ggthemes)
library(scales)
```

```
##
## Attaching package: 'scales'
```

```
## The following object is masked from 'package:purrr':
##
##     discard
```

```
## The following object is masked from 'package:readr':
##
##     col_factor
```

```
# datos
pee <- read.dta("./datos/EEpooled.dta")

str(pee) #estructura
```

```
## 'data.frame':    8 obs. of  9 variables:
##  $ outcome: Factor w/ 4 levels "CvA","CvD","ReA",..: 4 4 3 3 2 2 1 1
##  $ mmp    : num  0.31 0.31 0.89 0.89 0.81 0.81 1 1
##  $ exp    : Factor w/ 2 levels "Cold","Heat": 1 2 1 2 1 2 1 2
##  $ LCImmp : num  0.24 0.24 0.85 0.85 0.65 0.65 1 1
##  $ UCImmp : num  0.42 0.42 1 1 0.84 0.84 1 1
##  $ exp_1  : Factor w/ 2 levels "Cold","Heat": 1 2 1 2 1 2 1 2
##  $ RR     : num  1.15 1.63 1.33 1.04 1.32 ...
##  $ lowRR  : num  1.051 1.448 1.185 0.974 1.223 ...
##  $ highRR : num  1.27 1.83 1.49 1.11 1.42 ...
##  - attr(*, "datalabel")= chr "Written by R.              "
##  - attr(*, "time.stamp")= chr ""
##  - attr(*, "formats")= chr [1:9] "%9.0g" "%9.0g" "%9.0g" "%9.0g" ...
##  - attr(*, "types")= int [1:9] 108 100 108 100 100 108 100 100 100
##  - attr(*, "val.labels")= chr [1:9] "outcome" "" "exp" "" ...
##  - attr(*, "var.labels")= chr [1:9] "outcome" "mmp" "exp" "LCImmp" ...
##  - attr(*, "version")= int 7
##  - attr(*, "label.table")=List of 3
##   ..$ outcome: Named int [1:4] 1 2 3 4
##   .. ..- attr(*, "names")= chr [1:4] "CvA" "CvD" "ReA" "ReD"
##   ..$ exp    : Named int [1:2] 1 2
##   .. ..- attr(*, "names")= chr [1:2] "Cold" "Heat"
##   ..$ exp_1  : Named int [1:2] 1 2
##   .. ..- attr(*, "names")= chr [1:2] "Cold" "Heat"
```

```
pee <- mutate(pee, cause = str_sub(outcome, 1, 2) %>%
                           factor(c("Re", "Cv"), c("Respiratory", "Cardiovascular")),
                   outcome = str_sub(outcome, 3, 3) %>%
                           factor(c("D","A"), c("Deaths", "Hospital admissions"))
                    )

pee_ta <- read.dta("./datos/EEpooledCurves.dta")
```

```
str(pee_ta) # estructura
```

```
## 'data.frame':    412 obs. of  6 variables:
##  $ outcome: Factor w/ 4 levels "CvA","CvD","ReA",..: 4 4 4 4 4 4 4 4 4 4 ...
##  $ mmp    : num  0.31 0.31 0.31 0.31 0.31 0.31 0.31 0.31 0.31 0.31 ...
##  $ TempPer: num  0 0.01 0.02 0.025 0.03 0.04 0.05 0.06 0.07 0.08 ...
##  $ RR     : num  1.19 1.17 1.16 1.16 1.15 ...
##  $ lowRR  : num  1.07 1.06 1.06 1.05 1.05 ...
##  $ highRR : num  1.32 1.3 1.28 1.27 1.26 ...
##  - attr(*, "datalabel")= chr "Written by R.              "
##  - attr(*, "time.stamp")= chr ""
##  - attr(*, "formats")= chr [1:6] "%9.0g" "%9.0g" "%9.0g" "%9.0g" ...
##  - attr(*, "types")= int [1:6] 108 100 100 100 100 100
##  - attr(*, "val.labels")= chr [1:6] "outcome" "" "" "" ...
##  - attr(*, "var.labels")= chr [1:6] "outcome" "mmp" "TempPer" "RR" ...
##  - attr(*, "version")= int 7
##  - attr(*, "label.table")=List of 1
##   ..$ outcome: Named int [1:4] 1 2 3 4
##   .. ..- attr(*, "names")= chr [1:4] "CvA" "CvD" "ReA" "ReD"
```

```
pee_ta <- mutate(pee_ta, cause = str_sub(outcome, 1, 2) %>%
                                    factor(c("Cv", "Re"), c("Cardiovascular", "Respiratory")),
                         outcome = str_sub(outcome, 3, 3) %>%
                                   factor(c("D","A"), c("Deaths", "Hospital admissions"))
                  )
```

En primer gráfico mostraremos los riesgos relativos por causas específicas y por efecto de calor y frío en España. En el primer paso, creamos una variable con las etiquetas que complementarán las líneas de rango. Además, fijamos la posición dónde queremos que aparezcan los texto en el eje y.

Combinaremos geometría de rango de línea con un punto para lograr una barra de error. Para agrupar las barras debemos hacer uso de la posición diferenciada vía el uso de `position_dodge()` en `geom_linerange()`, `geom_point()` y `geom_text()`. Adicionalmente, es necesario dar más margen a las etiquetas modificando el margen derecho del gráfico en `theme()` y permitir la salida fuera del *plot* (`clip = "off"`). La función `facet_grid()` nos permite crear varios paneles de la misma geometría en función de otra variable lo que aquí sería el efecto por calor y frío.

```
## pooled overall
pee <- mutate(pee, lab = str_c(number(RR, big.mark = "", accuracy = .01), " (",
                               number(lowRR, big.mark = "", accuracy = .01), "; ",
                               number(highRR, big.mark = "", accuracy = .01),")"),
              ylab = ifelse(exp == "Heat", 1.9, 1.6))



ggplot(pee,
       aes(cause, RR,
           ymin = lowRR,
           ymax = highRR,
           colour = outcome,
           group = outcome)) +
  geom_hline(yintercept = 1) +
  geom_linerange(position = position_dodge(width = .5)) +
  geom_point(position = position_dodge(width = .5),
             fill = "white",
```

```
             shape = 21,
             size = 1.5) +
  geom_text(aes(cause, ylab, label = lab),
            colour = "black", size = 3,
            hjust = 0, fontface = "bold",
            position = position_dodge(width = .5)) +
scale_color_brewer(palette = "Set1") +
scale_y_continuous(breaks = seq(0, 2, .2), limit = c(0.8, 2)) +
labs(colour = "", y = "RR", x = "") +
facet_wrap(~ exp) +
coord_flip(clip = "off") +
theme_hc() +
theme(plot.margin = margin(r = 50))
```

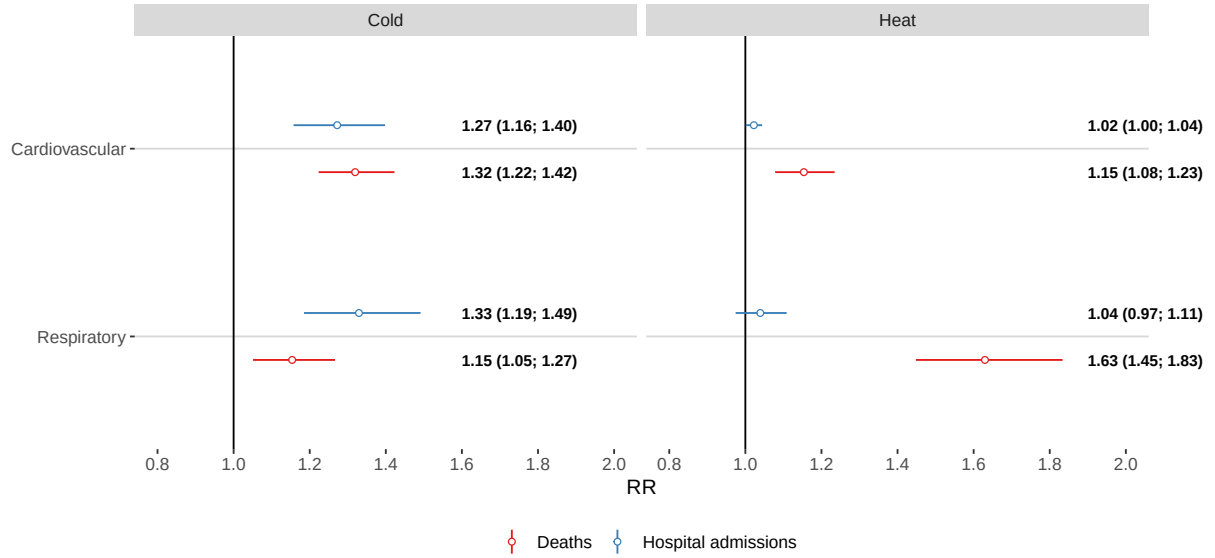

En el siguiente gráfico presentaremos los riesgos acumulados globales de España según el centil de temperatura. Para crear el intervalo de confianza en forma de un area gris de fondo empleamos la geometría `geom_ribbon()`. Las funciones `geom_h*vline()` nos ayudan en crear líneas verticales o horizontales en la intersección indicada para x o y.

```
## pooled by ta
ggplot(pee_ta) +
  geom_hline(yintercept = 1) +
  geom_vline(aes(xintercept = mmp,
                 colour = outcome),
             linetype = "dashed",
             show.legend = FALSE) +
  geom_ribbon(aes(TempPer,
                  ymin = lowRR,
                  ymax = highRR,
                  group = outcome),
              fill = "grey70",
              alpha = 0.3) +
  geom_line(aes(TempPer, RR,
                colour = outcome,
                group = outcome),
            size = 1) +
```

```
  facet_grid(~ cause) +
  coord_cartesian(ylim=c(0.9, 2)) +
  scale_x_continuous(breaks = seq(0, 1, 0.1),
                     labels = scales::percent_format(accuracy = 1)) +
  scale_y_continuous(breaks = seq(0, 2, 0.1),
                     limit = c(0.9, 2)) +
  scale_color_brewer(palette = "Set1") +
  theme_classic() +
  theme(legend.position = "bottom",
        panel.border = element_rect(fill = "transparent"),
        strip.background = element_rect(colour = NA , fill = "grey85")) +
  labs(x = "Temperature percentiles", colour = "")
```

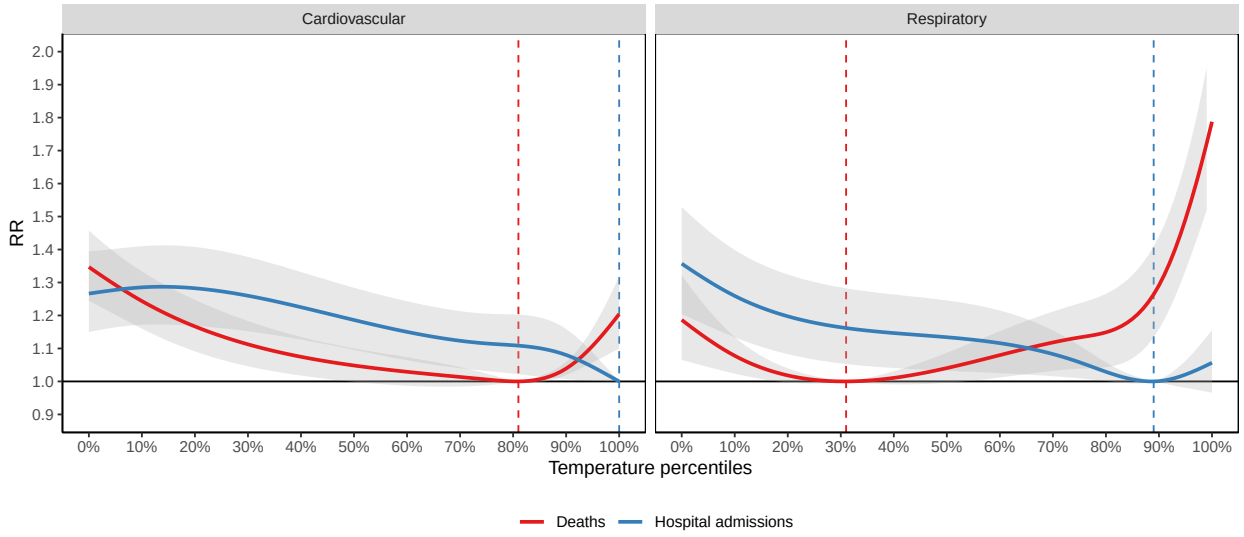

Aplicar funciones sobre vectores o listas

El paquete `purrr` contiene un conjunto de funciones avanzadas de programación funcional para trabajar con funciones y vectores. La familia de funciones `lapply()` conocido de `R Base`corresponde a las funciones de `map()` en este paquete. Una de las mayores ventajas es poder reducir el uso de bucles (`for`, etc.). Otras variantes son `walk()`, `map2()` ó `map_depth()`.

```
# lista con dos vectores
vec_list <- list(x = 1:10, y = 50:70)

# calculamos el promedio para cada uno
map(vec_list, mean)
```

```
## $x
## [1] 5.5
##
## $y
## [1] 60
```

```
# podemos cambiar tipo de salida map_* (dbl, chr, lgl, etc.)
map_dbl(vec_list, mean)
```

```
##    x    y
##  5.5 60.0
```

Un ejemplo más complejo. Calculamos el coeficiente de correlación entre la movilidad residencial y la de los parques en todos los países europeos. Para obtener un resumen *tidy* de un modelo o un test usamos la función `tidy()` del paquete `broom`.

```
library(broom) # tidy outputs

# función adaptada
cor_test <- function(x, formula) {

df <- cor.test(as.formula(formula), data = x) %>% tidy()

return(df)

}

# preparamos los datos
europe_reg <- filter(google_mobility,
                           !is.na(sub_region_1),
                           !is.na(residential_percent_change_from_baseline)) %>%
                     left_join(wld, by = c("country_region_code"="iso_a2")) %>%
                     filter(subregion %in% c("Northern Europe",
                                             "Southern Europe",
                                              "Western Europe",
                                              "Eastern Europe"))
# aplicamos la función a cada país creando una lista
europe_reg %>%
  split(.$country_region_code) %>%
  map(cor_test, formula = "~ residential_percent_change_from_baseline + parks_percent_change_from_baseli
```

```
## $AT
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.360     -12.3 2.68e-32      1009   -0.413    -0.305 Pearson'~ two.sided
##
## $BE
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.312     -6.06  3.67e-9       340   -0.405    -0.213 Pearson'~ two.sided
##
## $BG
## # A tibble: 1 x 8
##   estimate statistic   p.value parameter conf.low conf.high method   alternative
##      <dbl>     <dbl>     <dbl>     <int>    <dbl>     <dbl> <chr>    <chr>
## 1   -0.677     -37.8 1.47e-227      1694   -0.702    -0.650 Pearson~ two.sided
##
## $CH
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1  -0.0786     -2.91 0.00370      1360   -0.131   -0.0256 Pearson's~ two.sided
##
## $CZ
## # A tibble: 1 x 8
```

```
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1  -0.0837     -3.35 0.000824      1593   -0.132   -0.0347 Pearson'~ two.sided
##
## $DE
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1  0.00239     0.102   0.919      1814  -0.0436    0.0484 Pearson's~ two.sided
##
## $DK
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1    0.237      5.81  1.04e-8       567    0.158     0.313 Pearson'~ two.sided
##
## $EE
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1   -0.235     -2.88 0.00462       142   -0.384   -0.0740 Pearson's~ two.sided
##
## $ES
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1   -0.825     -65.4       0      2005   -0.839    -0.811 Pearson's~ two.sided
##
## $FI
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1   0.0427      1.42   0.155      1106  -0.0162     0.101 Pearson's~ two.sided
##
## $FR
## # A tibble: 1 x 8
##   estimate statistic   p.value parameter conf.low conf.high method   alternative
##      <dbl>     <dbl>     <dbl>     <int>    <dbl>     <dbl> <chr>    <chr>
## 1   -0.698     -37.4 3.29e-216      1474   -0.723    -0.671 Pearson~ two.sided
##
## $GB
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.105     -11.0 9.19e-28     10712   -0.124   -0.0865 Pearson'~ two.sided
##
## $GR
## # A tibble: 1 x 8
##   estimate statistic   p.value parameter conf.low conf.high method   alternative
##      <dbl>     <dbl>     <dbl>     <int>    <dbl>     <dbl> <chr>    <chr>
## 1   -0.692     -27.0 1.03e-114       796   -0.726    -0.654 Pearson~ two.sided
##
## $HR
## # A tibble: 1 x 8
```

```
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.579     -21.9 9.32e-87       954   -0.620    -0.536 Pearson'~ two.sided
##
## $HU
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.342     -15.6 6.71e-52      1843   -0.382    -0.301 Pearson'~ two.sided
##
## $IE
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.222     -8.45 7.49e-17      1378   -0.271    -0.171 Pearson'~ two.sided
##
## $IT
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1   -0.831     -71.0       0      2250   -0.844    -0.818 Pearson's~ two.sided
##
## $LT
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.204     -5.45  7.17e-8       686   -0.274    -0.131 Pearson'~ two.sided
##
## $LV
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.544     -6.87 3.84e-10       112   -0.662    -0.401 Pearson'~ two.sided
##
## $NL
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1    0.143      5.31  1.25e-7      1356   0.0903     0.195 Pearson'~ two.sided
##
## $NO
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1   0.0483      1.69  0.0911      1221 -0.00774     0.104 Pearson's~ two.sided
##
## $PL
## # A tibble: 1 x 8
##   estimate statistic   p.value parameter conf.low conf.high method   alternative
##      <dbl>     <dbl>     <dbl>     <int>    <dbl>     <dbl> <chr>    <chr>
## 1   -0.531     -26.7 6.08e-133      1815   -0.564    -0.498 Pearson~ two.sided
##
## $PT
## # A tibble: 1 x 8
```

```
##   estimate statistic   p.value parameter conf.low conf.high method   alternative
##      <dbl>     <dbl>     <dbl>     <int>    <dbl>     <dbl> <chr>    <chr>
## 1   -0.729     -46.9 2.12e-321      1938   -0.749    -0.707 Pearson~ two.sided
##
## $RO
## # A tibble: 1 x 8
##   estimate statistic p.value parameter conf.low conf.high method     alternative
##      <dbl>     <dbl>   <dbl>     <int>    <dbl>     <dbl> <chr>      <chr>
## 1   -0.640     -56.0       0      4517   -0.657    -0.623 Pearson's~ two.sided
##
## $SE
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1    0.106      3.93  9.09e-5      1367   0.0529     0.158 Pearson'~ two.sided
##
## $SI
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.627     -11.4 1.98e-23       200   -0.704    -0.535 Pearson'~ two.sided
##
## $SK
## # A tibble: 1 x 8
##   estimate statistic  p.value parameter conf.low conf.high method    alternative
##      <dbl>     <dbl>    <dbl>     <int>    <dbl>     <dbl> <chr>     <chr>
## 1   -0.196     -5.70  1.65e-8       810   -0.262    -0.129 Pearson'~ two.sided
```

Como ya hemos visto anteriormente, existen subfunciones de `map_*` para obtener en lugar de una lista un objeto de otra clase, aquí de `data.frame`.

```
cor_mobility <- europe_reg %>%
                  split(.$country_region_code) %>%
                     map_df(cor_test,
                            formula = "~ residential_percent_change_from_baseline + parks_percent_chang
                            .id = "country_code")

arrange(cor_mobility, estimate)
```

```
## # A tibble: 27 x 9
##    country_code estimate statistic   p.value parameter conf.low conf.high method
##    <chr>           <dbl>     <dbl>     <dbl>     <int>    <dbl>     <dbl> <chr>
##  1 IT             -0.831    -71.0  0              2250   -0.844    -0.818 Pears~
##  2 ES             -0.825    -65.4  0              2005   -0.839    -0.811 Pears~
##  3 PT             -0.729    -46.9  2.12e-321      1938   -0.749    -0.707 Pears~
##  4 FR             -0.698    -37.4  3.29e-216      1474   -0.723    -0.671 Pears~
##  5 GR             -0.692    -27.0  1.03e-114       796   -0.726    -0.654 Pears~
##  6 BG             -0.677    -37.8  1.47e-227      1694   -0.702    -0.650 Pears~
##  7 RO             -0.640    -56.0  0              4517   -0.657    -0.623 Pears~
##  8 SI             -0.627    -11.4  1.98e- 23       200   -0.704    -0.535 Pears~
##  9 HR             -0.579    -21.9  9.32e- 87       954   -0.620    -0.536 Pears~
## 10 LV             -0.544     -6.87 3.84e- 10       112   -0.662    -0.401 Pears~
## # ... with 17 more rows, and 1 more variable: alternative <chr>
```

Otros ejemplos prácticos aquí en este post or este otro. Podemos encontrar más detalles en el Cheat-Sheet de `purrr`.