

Modelización de regresión de series temporales con R.

XIV Summer School MESIO UPC-UB.

Práctica Sesión 4: Modelo dlnm

Carmen Iñiguez

En esta sesión práctica veremos como resumir los resultados de múltiples localizaciones, para lo cual realizaremos 3 ejercicios cortos, que analizan (como ayer) la relación entre temperatura y mortalidad. Al acabar se propondrán un par de ejercicios más.

Hoy trabajaremos con la lista completa **dCV_94_06**, (archivo **datosSC.Rdata**) cuyos elementos son las bases de datos para las tres capitales de provincia de la Comunidad Valenciana: Alicante, Castellón y Valencia (es decir, los dos primeros elementos de la lista son bases análogas a la base de ayer, para las ciudades de Alicante y Castellón). Recordad: La variable **tm**, conteo diario de las defunciones por todas las causas, es nuestra variable respuesta y la variable **tmean**, temperatura media diaria, nuestro predictor.

Ejercicio 1

Estimaremos la relación **dosis-respuesta para el efecto total de temperatura** sobre la mortalidad en la Comunidad Valenciana, para el periodo 1994-2006. El análisis lo haremos en dos etapas. En la primera analizaremos los datos en cada ciudad separadamente, en la segunda combinaremos los resultados ciudad-específicos.

Paso 0: Preliminares.

```
rm(list=ls())
```

```
#librerías básicas
```

```
library(dlnm)
```

```
library(mvmeta)
```

```
library(mixmeta)
```

```

#datos
load("datosSC.RData")
dCV<-dCV_94_06

# parámetros del análisis
namesc<-names(dCV)
len<-length(namesc)
dfseas<-7

formula <-tm~cb+dow+ns(fecha,df=dfseas*length(unique(yy)))

varper<-c(10,50,90)
varfun<-"bs"

nlag<-21
xlag<-0:nlag
lagnk <- 3
klag<-logknots(nlag,lagnk)
lagfun<-"ns"
arlagm=list(fun=lagfun, knots=klag,int=T)

```

Pregunta 1: A la vista de estas especificaciones ¿hasta qué retardo vamos a analizar la asociación?

Pregunta 2: Indicar cómo va a modelizarse la relación lag-respuesta.

Etapla 1: Análisis individuales.

```

# Objetos para guardar resultados ciudad-específicos
red <- vector("list",len)
coef <- matrix(NA,len,length(varper)+3,dimnames=list(names(dCV)))

```

```

vcov <- vector("list",len); names(vcov) <- names(dCV)

# Bucle para el análisis

for(i in 1:len) {
  #extraemos los datos
  datai <- dCV[[i]]

  #especificamos la base
  knotsper <- quantile(datai$tmean, probs=varper/100, na.rm=T)
  argvarm <- list(fun=varfun,knots=knotsper,int=F)

  #obtenemos la base
  cb <- crossbasis(datai$tmean, lag=nlag, argvar=argvarm, arglag=arlagm)

  #ajustamos el modelo
  model <- glm(formula,datai,family=quasipoisson,na.action="na.exclude")

  #determinamos la malla de predicción
  tpred <- quantile(datai$tmean, probs=(1:99)/100, na.rm=T)

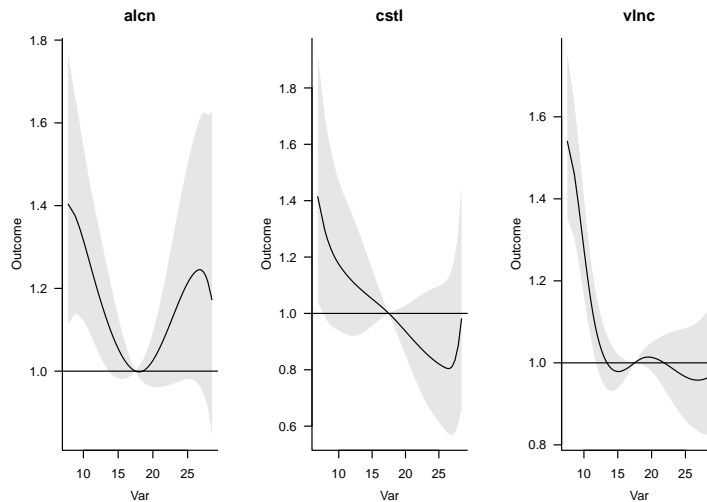
  #predicción reducida: overall
  red[[i]] <- crossreduce(cb,model,at=tpred)
  coef[i,] <- red[[i]]$coef
  vcov[[i]] <- red[[i]]$vcov

  cat("\t",i)
}

```

Podemos hacer una inspección rápida de los resultados en cada ciudad:

```
par(mfrow=c(1,3), mar=c(4,3.8,3,2.4),mgp=c(2.5,1,0),las=1)
for(i in seq(length(red))) {
  plot(red[[i]], main= names(dCV)[i])
}
```



Pregunta 3: ¿Dónde hemos puesto los knots en la estructura dosis-respuesta?

Pregunta 4: ¿Qué impresión te causan las curvas?

Etapla 2: Análisis combinado

En este segundo paso, en primer lugar obtendremos los coeficientes combinados y en segundo lugar realizaremos la predicción combinada.

```
mv <- mvmeta(coef~1,vcov,method="reml")
summary(mv)
```

Call: mvmeta(formula = coef ~ 1, S = vcov, method = "reml")

Multivariate random-effects meta-analysis

Dimension: 6

Estimation method: REML

Fixed-effects coefficients

	Estimate	Std. Error	z	Pr(> z)	95%ci.lb	95%ci.ub
y1	0.4112	0.6404	0.6421	0.5208	-0.8440	1.6664
y2	-0.1635	0.4367	-0.3743	0.7082	-1.0195	0.6925
y3	-0.1904	0.5172	-0.3682	0.7127	-1.2041	0.8232
y4	-0.1830	0.5244	-0.3489	0.7272	-1.2107	0.8448
y5	-0.2032	0.5574	-0.3645	0.7155	-1.2957	0.8893
y6	0.2553	0.8896	0.2869	0.7742	-1.4883	1.9989

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Between-study random-effects (co)variance components

Structure: General positive-definite

	Std. Dev	Corr					
y1	0.7686		y1	y2	y3	y4	y5
y2	0.4187	0.8730					
y3	0.5601	0.9993	0.8538				
y4	0.6108	0.8499	0.9990	0.8292			
y5	0.6326	0.9302	0.9911	0.9155	0.9840		
y6	0.7292	-0.2123	-0.6620	-0.1749	-0.6954	-0.5562	

Multivariate Cochran Q-test for heterogeneity:

Q = 16.8093 (df = 12), p-value = 0.1569

I-square statistic = 28.6%

3 studies, 18 observations, 6 fixed and 21 random-effects parameters

logLik	AIC	BIC
-5.5581	65.1163	78.2088

Pregunta 5: ¿Hay heterogeneidad? ¿Cuanta?

Pregunta 6: ¿Te dice algo la estimación de los coeficientes?

Para la predicción combinada necesitaremos montar los coeficientes sobre una crossbasis, idealmente la misma con la que se realizaron los análisis ciudad-específicos. Haciendo el análisis en escala absoluta, éste es un punto problemático, ya que existen varias opciones y ninguna es perfecta. Una opción podría ser considerar la distribución conjunta de temperatura en las tres ciudades para ubicar nodos y mallado de predicción:

```
tmeanCV <-c(dCV[[1]]$tmean,dCV[[2]]$tmean,dCV[[3]]$tmean )
knotsper<-quantile(tmeanCV, probs=varper/100, na.rm=T)
tpred <-quantile(tmeanCV, probs=1:99/100, na.rm=T)

argvarm<-list(fun=varfun, knots=knotsper)
arglagm<-list(fun=lagfun, knots=klag)
cb <- crossbasis(tpred, lag=nlag, argvar=argvarm, arglag=arglagm)
bvar <- do.call("onebasis",c(list(x=tpred),attr(cb,"argvar"))))

# Predicción overall combinada sin centrar
Metapred<-crosspred(basis=bvar,coef=coef(mv),vcov=vcov(mv),at=tpred,
                    model.link="log")


# Predicción overall combinada centrada en mmt
metaMMT<-Metapred$predvar[which.min(Metapred$allfit)]
Metapred<-crosspred(basis=bvar,coef=coef(mv),vcov=vcov(mv),cen=metaMMT,
                    at=tpred, model.link="log")

#Predicción blup (fixef+ranef)
```

```
blups <- blup(mv,vcov=TRUE)
```

Una inspección rápida de la curva promedio para la Comunidad Valenciana:

```
plot(Metapred, ylim=c(0.75,3))
```



Pregunta 7: Interpreta la curva resumida ¿Hay efecto del frío? ¿Y del calor?

Ejercicio 2

Estimaremos la relación **dosis-respuesta para el efecto total de temperatura** sobre la mortalidad en la Comunidad Valenciana, para el periodo 1994-2006, usando una **escala relativa en percentiles** para la temperatura.

Paso 0: Preliminares.

a) Relativización de temperatura

Se trata de escalar los datos de temperatura en cada serie, para poder utilizar la misma base en todas las ciudades:

```
for(i in 1:len){  
  Fd<-ecdf(dCV[[i]]$tmean)  
  dCV[[i]]$ptmean<-Fd(dCV[[i]]$tmean)}
```

b) Creación de la base

Trabajar en escala relativa, tiene la ventaja de que la base y el mallado para la predicción estarán en términos de orden de percentil y serán exactamente los mismos en todos los análisis. Por tanto, pueden ser definidos a priori:

```
varper<-c(10,50,90)  
knotsper <- varper/100  
varfun<-"bs"  
  
nlag<-21  
xlag<-0:nlag  
lagnk <- 3  
klag<-logknots(nlag,lagnk)  
lagfun<-"ns"  
  
argvarm <- list(fun=varfun, knots=knotsper, int=F)  
arglagm <- list(fun=lagfun, knots=klag, int=T)
```



```

cb <- crossbasis(tpred, lag=nlag, argvar=argvarm, arglag=arglagm)
bvar <- do.call("onebasis", c(list(x=tpred), attr(cb,"argvar")))
blag <- do.call("onebasis", c(list(x=xlag), attr(cb,"arglag")))

tpred <- (1:99)/100

```

Etapa 1: Análisis individuales.

```

red<-vector("list",len)
coef<-matrix(NA,len,length(varper)+3,dimnames=list(names(dCV)))
vcov<- vector("list",len); names(vcov) <- names(dCV)

for(i in 1:len) {

  datai <- dCV[[i]]
  argvar <- list(fun=varfun,knots=knotsper)
  cb <- crossbasis(datai$ptmean, lag=nlag, argvar=argvarm, arglag=arglagm)
  model <- glm(formula,datai,family=quasipoisson,na.action="na.exclude")
  red[[i]] <- crossreduce(cb,model,at=tpred)
  coef[i,] <- red[[i]]$coef
  vcov[[i]] <- red[[i]]$vcov
}

```

Etapa 2: Análisis combinado

```

mv<- mvmeta(coef~1,vcov,method="reml",control=list(showiter=T))

bvar <- do.call("onebasis",c(list(x=tpred),attr(cb,"argvar")))
Metapred<-crosspred(basis=bvar,coef=coef(mv),vcov=vcov(mv),
                    at=tpred,model.link="log")
metaMMT<-Metapred$predvar[which.min(Metapred$allfit)]
Metapred<-crosspred(basis=bvar,coef=coef(mv),vcov=vcov(mv),cen=metaMMT,


```

```
at=tpred,model.link="log")
```

```
blups <- blup(mv,vcov=TRUE)
```

Curva promedio:

```
plot(Metapred)
```



Pregunta 8: ¿Cual es el percentil de temperatura asociado a la mínima mortalidad?

Pregunta 9: ¿Hay Heterogeneidad? ¿Cuanta?

Pregunta 10: Interpreta la curva resumida ¿Hay efecto del frío? ¿Y del calor?

Ejercicio 3

Estimaremos la relación **lag-respuesta para el efecto del percentil 95 de temperatura** sobre la mortalidad en la Comunidad Valenciana, para el periodo 1994-2006, usando una **escala relativa en percentiles** para la temperatura.

Los preliminares serían exactamente los mismos que en el ejercicio anterior.

Etapla 1: Análisis individuales.


```
coef<-matrix(NA,len,length(varper)+2,dimnames=list(names(dCV)))
vcov<- vector("list",len)
names(vcov) <- names(dCV)

mmp<-0.93

for(i in 1:len) {
  datai <- dCV[[i]]
  cb <- crossbasis(datai$ptmean, lag=nlag, argvar=argvarm, arglag=arglagm)
  model <- glm(formula,datai,family=quasipoisson,na.action="na.exclude")
  red <- crossreduce(cb, model, type = "var", value = 0.95, cen = mmp)
  mmp <- red$predvar[which.min(red$RRfit)]
  coef[i,] <- red$coef
  vcov[[i]] <- red$vcov
}
```

Etapla 2: Análisis combinado.

```
mv<- mvmeta(coef~1,vcov,method="reml",control=list(showiter=T))
Metapred<-crosspred(basis=blag,coef=coef(mv),vcov=vcov(mv), model.link="log")
plot(Metapred,ci="bars")
```



Pregunta 11: Interpreta la curva resumida para la distribución en los retardos del efecto del calor (P95)

Ejercicios

1. Estimar la relación **lag-respuesta para el efecto frío** (P5) usando las especificaciones del ejercicio 3
 2. Estudiar la relación entre temperatura y mortalidad circulatoria en la Comunidad valenciana considerando una ventana de 14 días.
-